任 昊

端侧大模型推理部署 | 模型量化 | NPU / GPU 算子 | AI 应用

18906839529 | renhao19971222@gmail.com | 微信 & GitHub：mononokehime14 | 2026 年底回国

教育背景

美国卡耐基梅隆大学（CMU） 移动与物联网工程 硕士 2022.09 – 2023.12

GPA 3.95/4.0 | 助教：14-740 计算机网络 | 科研：斯坦福 SLAC 实验室

新加坡国立大学（NUS） 计算机工程 学士 2018.08 – 2022.06

GPA 4.36/5.0 | 科研：南洋理工大学 ROSE 实验室、Mehul Motani 教授课题组

工作经历

高通（Qualcomm） 人工智能工程师 美国 · 圣地亚哥 2024.01 – 至今

- **端侧 LLM 部署：**基于 QAIRT（QNN/SNPE）在数款骁龙 NPU（HTP）上首次跑通 Qwen3.5 4B、Qwen2.5-Omni 3B/7B、Qwen3-Embedding / Reranker，性能优于 CPU 与 llama.cpp 的 GPU/OpenCL 路径。
- **量化方案：**使用 AdaScale、LPQB、SeqMSE 等 PTQ 与混合精度，将上述模型的量化损失压到 15% 以内。
- **多 NPU 并行：**为端侧推理框架 Genie 设计并实现多 NPU 并行，IQ-9075 上 LLM prefill 提升 1.55 倍以上。
- **GPU 算子优化：**定位 llama.cpp OpenCL（ggml）视觉编码瓶颈，换 kernel_mul_mat_fp16_fp32_l4 内核提速 10 倍；再以 ggml_contiguous 重排 Q/K 走 fp16_fp32_i4_lm 内核，再提速 40%，矩阵乘总提速逾 16 倍。
- **多模态 RAG：**用 LangChain、FAISS 与 llama.cpp 构建多模态 RAG，量化编译后首次落地高通 Linux 芯片。
- **企业级 RAG：**与沙特阿美（Aramco）合作，利用私有数据微调 BGE 模型，检索 Top-5 提升 15%、端侧精度达云端 91%；加装 Reranker 后，Faithfulness 再提升 10% 以上。
- **CNN 量化部署：**用 QAT / PTQ（CLE 等）量化 MobileNet、PoseNet、FlowNet 至端侧物联网芯片，部分模型精度提升达 29%、逼近 FP32；已随客户产品商用并亮相 CES。
- **GPU 部署探索：**用 TVM 在 Adreno GPU 上部署 CNNs 模型，性能较 QAIRT 路径提升一倍以上，部分模型可达 500+ IPS。
- **算法与专利：**为物流移动场景的低功耗物联网设备设计聚类算法（DBSCAN/ST-DBSCAN），精度（AMI/ARI）提升 5.49%，已提交专利 2501665 IDF（Grouping based on Location and Context）。

实习经历

高通（Qualcomm） AI/ML 工程实习生 美国 · 圣地亚哥 2023.05 – 2023.08

- 用 Python + PyTorch 搭建端到端 ML/DL 全生命周期框架 Qflow，支持项目 / 代码级复用、自动化管理、量化与 SoC 部署。
- 基于该框架落地 Asset Inspection（目标检测 + 异常检测）：仅用数张目标图片（Few-shot）即可定位异常区域，在移动设备芯片上达 31.02 FPS，并代表 IoT 部门向高通 CEO/CFO 汇报展示。

新加坡能源集团（SP Group） 人工智能工程实习生 新加坡 2021.01 – 2021.06

- 搭建异常检测与误报治理平台：用 XGBoost 识别并删减告警误报，大幅降低人工复核成本；配套的 Python 可视化网站用 TreeSHAP 解释模型决策，并用 PostgreSQL 预存计算结果，单次查询提速 95.8%。
- 对电气集中装置的时序数据做异常检测：用 PyTorch 开发可插拔训练框架，按工作日 / 周末分别训练 Autoencoder，准确率提升 8%。

中国科学院嘉兴光电工程中心 软件工程实习生 浙江 · 嘉兴 2019.05 – 2019.08

- 用 Qt5 开发图像处理软件（多窗口同步、拉普拉斯锐化、灰度化），支撑 3D 建模与激光扫描项目。
- 用 C++ 实现 K-means + Otsu 快速图像分割，用于激光扫描中的目标提取。

科研经历

南洋理工大学（NTU） ROSE 实验室 · 研究助理 新加坡 2021.08 – 2022.06

- 将原始音频转为频域图像，用 ResNet50 检测 AI 合成语音，准确率 98%（较当时 SOTA 高 3%）。
- 研究 I3D、C3D、Two Stream 等 DeepFake 方法；
  运用人体语义解析将遮挡行人重识别的 mAP 提升 2–3%。

新加坡国立大学（NUS） 研究助理 新加坡 2021.08 – 2022.08

- 在 MIMIC-IV 上验证 CURATE.AI（按给药剂量动态预测个体药物反应），并与医生合作给出糖尿病、高血压患者的个体化剂量建议。

项目经历

斯坦福 SLAC 实验室 | 合成音频检测 | TTS · DeepFake · AWS MLOps 2023 秋

- 在 AWS 搭建 TTS 训练与部署流水线（S3、Lambda、SageMaker），用户可经 API Gateway 自助生成合成音频数据集。
- 微调 yourTTS / VITS 复刻自采人声，演示中高度还原目标音色。

CMU 15-418 | 并行编程 | 高性能计算 · 分布式训练 2023 春

- 用 C++ 从零实现并行 Transformer 推理：4 进程流水线并行 + 单层内张量并行，加速达到 4.82 倍。
- 用 CUDA 实现半透明圆形并行渲染，借共享内存 exclusive scan 将 10 万圆渲染压到 12 ms 内。
- 用 OpenMP + 四叉树实现 20 万粒子 N-Body 模拟，加速 8 倍。

机器学习动作识别系统（本科毕设） | 嵌入式 · 时序数据 · FPGA 部署 · 物联网 2021 秋

- 构建端到端舞蹈动作识别系统：可穿戴传感器 + 蓝牙 + CNN + FPGA 部署 + 可视化网站。
- 用 TensorFlow 训练 CNN，配以平滑与滑窗切分预处理，实地测试达 100% 准确率。

专业技能

端侧部署： QAIRT（QNN/SNPE）、Genie、HTP/HVX/VTCM、llama.cpp/ggml、TVM、TFLite/ONNX、vLLM

模型量化： QAT / PTQ（AdaScale、LPQB、SeqMSE、CLE）、校准与混合精度

算子与并行： CUDA / OpenCL / OpenMP / MPI、kernel 调优、性能分析

模型应用： RAG、Agentic RAG、LangChain、FAISS、TTS、DeepFake、VLM、Computer Vision、CNNs、ML

编程与框架： PyTorch / TensorFlow 、C / C++、Python、Java、TypeScript、SQL；Linux、Docker、K8s、AWS